



ACTIVIDAD CALIFICADA

I. DATOS INFORMATIVOS:

- **Título** : Big Data: comparación y análisis de herramientas para el procesamiento masivo de datos educativos.
- **Tipo de participación** : Individual
- **Docente del curso** : ARTEMIO. CALDERON PEREZ

Integrante

1. Matias Angulo Ruiz- N00381394

Introducción

En la actualidad, el crecimiento exponencial de los datos ha generado la necesidad de herramientas capaces de procesar, almacenar y analizar grandes volúmenes de información de manera eficiente. El concepto de **Big Data** engloba tecnologías diseñadas para manejar datos caracterizados por su volumen, velocidad y variedad.

Este informe presenta una comparación de cinco herramientas ampliamente utilizadas en entornos Big Data, con el fin de analizar sus características, ventajas, desventajas y contextos de aplicación.

Objetivo del informe

Analizar y comparar cinco herramientas de Big Data para identificar sus principales diferencias, ventajas, limitaciones y casos de uso, permitiendo determinar cuál es más adecuada según diferentes necesidades.

Desarrollo

4.1 Herramientas seleccionadas

- Hadoop
- Spark
- Kafka
- Hive
- HBase

Descripción de las herramientas

1. Hadoop

- **Definición:** Framework de código abierto para almacenamiento y procesamiento distribuido.
- **Función principal:** Procesar grandes volúmenes de datos en clústeres.
- **Características:**

HDFS (almacenamiento distribuido)

MapReduce (procesamiento por lotes)

- **Ventajas:**

Escalable

Económico (hardware común)

- **Desventajas:**

Procesamiento lento (batch)

Complejo de configurar

- **Casos de uso:**

Análisis de grandes datasets históricos

Spark

- **Definición:** Motor de procesamiento de datos en memoria.
- **Función principal:** Procesamiento rápido de datos.

- **Características:**

Procesamiento en memoria

Soporte para streaming y machine learning

- **Ventajas:**

Muy rápido

Versátil

- **Desventajas:**

Mayor consumo de memoria

- **Casos de uso:**

Análisis en tiempo real

Machine Learning

Kafka

- **Definición:** Plataforma de streaming distribuido.
- **Función principal:** Gestión de flujos de datos en tiempo real.
- **Características:**

Publicación/suscripción

Alta tolerancia a fallos

- **Ventajas:**

Alta velocidad

Escalable

- **Desventajas:**

No almacena datos a largo plazo

- **Casos de uso:**

Sistemas de mensajería

Streaming de datos

Hive

- **Definición:** Sistema de data warehouse basado en Hadoop.

- **Función principal:** Consultas SQL sobre grandes datos.

- **Características:**

Lenguaje HiveQL

Integración con Hadoop

- **Ventajas:**

Fácil de usar (similar a SQL)

- **Desventajas:**

No es eficiente para tiempo real

- **Casos de uso:**

Análisis de datos estructurados

HBase

- **Definición:** Base de datos NoSQL distribuida.
- **Función principal:** Almacenamiento de datos en tiempo real.
- **Características:**

Basado en columnas

Alta escalabilidad

- **Ventajas:**

Acceso rápido a grandes volúmenes

- **Desventajas:**

Complejo de administrar

- **Casos de uso:**

Aplicaciones en tiempo real

Cuadro comparativo

Herramienta	Tipo	Procesamiento	Velocidad	Uso principal	Ventaja clave	Desventaja clave
Hadoop	Framework	Batch	Baja	Procesamiento masivo	Escalable	Lento

Herramienta	Tipo	Procesamiento	Velocidad	Uso principal	Ventaja clave	Desventaja clave
Spark	Motor	En memoria	Alta	Tiempo real	Muy rápido	Alto consumo RAM
Kafka	Streaming	Tiempo real	Muy alta	Flujo de datos	Alta velocidad	No almacena datos
Hive	Data Warehouse	Batch	Media	Consultas SQL	Fácil uso	No tiempo real
HBase	NoSQL	Tiempo real	Alta	Almacenamiento	Acceso rápido	Complejo

Análisis crítico

Cada herramienta cumple un rol específico dentro del ecosistema Big Data, por lo que su eficiencia depende del contexto.

- **Spark** es la herramienta más eficiente cuando se requiere velocidad y procesamiento en tiempo real.
- **Hadoop** es ideal para almacenamiento y procesamiento de grandes volúmenes históricos, aunque es más lento.
- **Kafka** destaca en sistemas donde el flujo continuo de datos es clave, como aplicaciones en tiempo real.
- **Hive** facilita el acceso a datos mediante SQL, pero no es adecuado para procesamiento inmediato.
- **HBase** permite acceso rápido a datos, siendo útil en aplicaciones dinámicas.

¿Cuándo usar cada una?

- Hadoop → análisis masivo offline

- Spark → análisis rápido y ML
- Kafka → streaming de datos
- Hive → consultas SQL
- HBase → bases de datos NoSQL en tiempo real

Limitaciones

- Hadoop: baja velocidad
- Spark: alto consumo de recursos
- Kafka: no es base de datos
- Hive: no es tiempo real
- HBase: complejidad

Aporte al Big Data

Estas herramientas permiten:

- Procesar datos masivos
- Reducir tiempos de análisis
- Manejar datos estructurados y no estructurados
- Escalar sistemas fácilmente

Conclusiones

- No existe una herramienta única que resuelva todos los problemas de Big Data.
- La combinación de herramientas (ecosistema) es la mejor solución.
- Spark destaca por su velocidad y versatilidad.
- Hadoop sigue siendo fundamental para almacenamiento.
- Kafka es clave en arquitecturas modernas de streaming.

Bibliografía

Apache Software Foundation. (s.f.). *Apache Hadoop Documentation*.
<https://hadoop.apache.org/docs/>

Apache Software Foundation. (s.f.). *Apache Spark Documentation*.
<https://spark.apache.org/docs/latest/>

Apache Software Foundation. (s.f.). *Apache Kafka Documentation*.
<https://kafka.apache.org/documentation/>

Apache Software Foundation. (s.f.). *Apache Hive Documentation*.
<https://hive.apache.org/>

Apache Software Foundation. (s.f.). *Apache HBase Reference Guide*.
<https://hbase.apache.org/book.html>